

Projet 1 DAAR 2025

Breton Noé

n°21516014

Boudrouss Réda

n°28712638



Sorbonne Université
France

Table des matières

| | |
|--|-----------|
| 1. Introduction | 2 |
| 1.2. Contexte | 2 |
| 1.3. Démarche | 2 |
| 1.4. Architecture Technique | 2 |
| 1.5. Organisation du Rapport | 2 |
| 2. Fondements Théoriques | 3 |
| 2.1 Arbre Syntaxique Abstrait (AST) | 3 |
| 2.2 Construction du NFA (Automate Fini Non-Déterministe) | 3 |
| 2.2.1 Définition | 3 |
| 2.2.2 Construction de Thompson (Algorithme d'Aho-Ullman) | 3 |
| 2.2.3 Fermeture ϵ (Epsilon Closure) | 3 |
| 2.2.4 Matching avec NFA | 4 |
| 2.3 Conversion NFA vers DFA | 4 |
| 2.3.1 Définition du DFA | 4 |
| 2.3.2 Principe de la Méthode des Sous-Ensembles | 4 |
| 2.3.3 Gestion du Caractère Universel (DOT) | 4 |
| 2.3.4 Matching avec DFA | 4 |
| 2.4 Minimisation du DFA | 4 |
| 2.4.1 Motivation | 4 |
| 2.4.2 Principe de l'Algorithme de Partitionnement | 5 |
| 2.3 Algorithmes de Recherche Littérale | 5 |
| 2.3.1 Knuth-Morris-Pratt (KMP) | 5 |
| 2.3.2 Boyer-Moore | 5 |
| 2.4 Aho-Corasick : Recherche Multi-Motifs | 5 |
| 2.4.1 Principe | 5 |
| 2.4.2 Structure de Données | 5 |
| 2.4.3 Complexité | 6 |
| 3. Stratégies d'Optimisation | 6 |
| 3.1 Extraction de Littéraux et Préfiltrage | 6 |
| 3.2 Sélection Automatique d'Algorithme | 6 |
| 3.3 Lecture par Chunks | 7 |
| 4. Implémentation | 7 |
| 4.1 Interface CLI | 7 |
| 4.2 Mode de test de performance automatisé | 7 |
| 5. Résultats et Analyse de Performance | 8 |
| 5.1 Patterns Littéraux Courts vs Longs | 8 |
| 5.1.1 Pattern Court ("the") - 100 KB | 8 |
| 5.1.2 Pattern Long ("constitution") - 100 KB | 8 |
| 5.2 Scalabilité sur Fichiers Volumineux | 8 |
| 5.3 Patterns avec Alternations | 8 |
| 5.3.1 Alternation Simple ("cat dog bird") | 8 |
| 5.3.2 Pattern Complexe ("(a b).*c") | 9 |
| 5.4 Synthèse des Résultats | 9 |
| 5.4.1 Recommandations par Type de Pattern | 9 |
| 5.4.2 Trade-offs Mémoire vs Temps | 9 |
| 5.7 Discussion | 10 |
| 5.7.1 Efficacité de la Sélection Automatique | 10 |
| 5.7.2 Limites Observées | 10 |
| 6. Conclusion | 10 |
| 6.1 Synthèse des Contributions | 10 |
| 6.2 Résultats Obtenus | 11 |
| 6.3 Perspectives d'Amélioration | 11 |
| 6.4 Conclusion Générale | 11 |

1. Introduction

1.2. Contexte

Ce projet vise à développer un clone fonctionnel de **egrep** supportant un sous-ensemble de la norme ERE POSIX. Les opérateurs implémentés sont :

- Les parenthèses pour le groupement
- L’alternation (`|`) pour le choix entre motifs
- La concaténation de motifs
- L’étoile de Kleene (`*`) pour la répétition
- Le point (`.`) comme caractère universel
- Les caractères ASCII littéraux

L’approche classique décrite par Aho et Ullman dans *Foundations of Computer Science* consiste à :

1. Parser l’expression régulière en un arbre syntaxique
2. Construire un automate fini non-déterministe (NFA) avec ϵ -transitions
3. Convertir le NFA en automate fini déterministe (DFA) par la méthode des sous-ensembles
4. Minimiser le DFA pour réduire le nombre d’états
5. Utiliser l’automate pour matcher les lignes du fichier

1.3. Démarche

L’exécution d’un automate peut s’avérer parfois couteuse en temps (NFA) ou en mémoire (DFA). Nous avons donc aussi implémenté des algorithmes de recherche de motifs littéraux pour améliorer les performances dans certains cas. Notamment :

- Knuth-Morris-Pratt (KMP) : recherche linéaire garantie $O(n+m)$ pour les motifs courts
- Boyer-Moore : recherche optimisée pour les motifs longs avec heuristique du mauvais caractère
- Aho-Corasick : recherche multi-motifs pour les alternations de littéraux

D’autres améliorations ont été apportées pour gérer efficacement les fichiers volumineux :

- Analyse du pattern pour identifier les segments fixes
- Utilisation de Boyer-Moore ou Aho-Corasick pour éliminer rapidement les lignes non-candidates avant le matching regex complet
- Choix du meilleur algorithme en fonction de la complexité du pattern
- Traitement efficace de fichiers volumineux avec gestion mémoire optimisée

Nous nous sommes énormément inspirés de l’implémentation de GNU `grep` pour ce projet. Notamment, l’architecture par chunks et le préfiltrage sont directement inspirés de cette implémentation.

1.4. Architecture Technique

L’implémentation est réalisée en TypeScript dans une architecture monorepo comprenant :

- `lib` : bibliothèque core contenant tous les algorithmes (NFA, DFA, KMP, Boyer-Moore, Aho-Corasick, préfiltrage)
- `cli` : interface en ligne de commande compatible avec **egrep**

Le projet inclut une suite de tests exhaustive (Vitest) et des benchmarks de performance sur des corpus du projet Gutenberg.

Le choix de TypeScript a été fait pour son coté fonctionnel et son typage statique, mais aussi pour sa rapidité d’exécution après transpilation en JavaScript.

1.5. Organisation du Rapport

Ce rapport présente d’abord les fondements théoriques des algorithmes implémentés (Section 2), puis détaille les stratégies d’optimisation développées (Section 3). L’implémentation est exposée en Section 4, suivie d’une analyse de performance comparative (Section 5). Nous concluons par une discussion des résultats et des perspectives d’amélioration (Section 6).

2. Fondements Théoriques


2.1 Arbre Syntaxique Abstrait (AST)

Pour faciliter la manipulation et la transformation des expressions régulières, nous les représentons sous forme d'arbre syntaxique abstrait (Abstract Syntax Tree, AST).

Nous définissons un type `SyntaxTree` en TypeScript :

```
export type SyntaxTree =  
  | { type: "char"; value: string }           // Caractère littéral  
  | { type: "dot" }                           // Caractère universel '.'  
  | { type: "concat"; left: SyntaxTree; right: SyntaxTree } // Concaténation  
  | { type: "alt"; left: SyntaxTree; right: SyntaxTree }    // Alternation  
  | { type: "star"; child: SyntaxTree };                  // Étoile de Kleene
```

Exemple : L'expression régulière $(a|b)^*c$ est représentée par l'arbre :



Le parsing de l'expression régulière en arbre syntaxique est réalisé par un parseur récursif descendant. Cette technique consiste à définir une fonction de parsing pour chaque niveau de la grammaire, en respectant la hiérarchie de précedence. Chaque fonction lit l'entrée jusqu'à rencontrer un opérateur de niveau inférieur, puis appelle la fonction de parsing correspondant au niveau inférieur.

Le parsing s'effectue en $O(n)$ où n est la longueur de l'expression régulière, avec un seul passage sur l'entrée.

2.2 Construction du NFA (Automate Fini Non-Déterministe)

2.2.1 Définition

Nous représentons un NFA par un objet TypeScript contenant :

```
type NFA = {  
  states: state_ID[]; // ensemble fini d'états  
  // Dictionnaire des transitions, la clé est l'état source, la valeur est un dictionnaire avec la clé  
  // le symbole de transition et la valeur l'ensemble des états cibles  
  transitions: { [state: state_ID]: { [symbol: string]: state_ID[] } };  
  start: state_ID; // état initial  
  accepts: state_ID[]; // ensemble d'états acceptants  
};
```

Nous utilisons deux symboles spéciaux, `EPSILON` et `DOT`, pour représenter les ϵ -transitions et le caractère universel, respectivement.

Le caractère non-déterministe signifie que depuis un état donné, plusieurs transitions peuvent être possibles pour un même symbole, et que des ϵ -transitions (transitions sans consommer de caractère) sont autorisées.

2.2.2 Construction de Thompson (Algorithme d'Aho-Ullman)

La construction de Thompson est un algorithme récursif qui construit un NFA à partir d'un arbre syntaxique en appliquant des règles de composition pour chaque opérateur. Chaque sous-expression est transformée en un fragment de NFA avec un état initial et un état final unique.

La complexité est $O(n)$ où n est la taille de l'arbre syntaxique. Chaque nœud est visité exactement une fois, et chaque opération (création d'états, ajout de transitions) est en temps constant.

2.2.3 Fermeture ϵ (Epsilon Closure)

La fermeture ϵ d'un ensemble d'états S est l'ensemble de tous les états accessibles depuis S en suivant uniquement des ϵ -transitions. Cette opération est fondamentale pour le matching avec NFA et la conversion NFA \rightarrow DFA.

La complexité est $O(|Q| + |\delta|)$ où Q est l'ensemble des états et δ l'ensemble des transitions. Dans le pire cas, on visite tous les états et toutes les ϵ -transitions.

2.2.4 Matching avec NFA

Pour vérifier si une chaîne w est acceptée par un NFA, on simule l'exécution de l'automate en maintenant l'ensemble des états actifs à chaque étape.

La complexité est $O(|w| \times |Q|^2)$ où w est la longueur de l'entrée et Q l'ensemble des états. Pour chaque caractère, on peut avoir jusqu'à $|Q|$ états actifs, et la fermeture ϵ peut visiter tous les états.

2.3 Conversion NFA vers DFA

2.3.1 Définition du DFA

Nous représentons un DFA par un objet TypeScript contenant :

```
type DFA = {
  states: state_ID[];
  // On remarquera que contrairement au NFA, on a une seule cible par état et symbole
  transitions: { [state: state_ID]: { [symbol: string]: state_ID } };
  start: state_ID;
  accepts: state_ID[];
};
```

2.3.2 Principe de la Méthode des Sous-Ensembles

La construction par sous-ensembles (subset construction) transforme un NFA en un DFA équivalent. Le principe est que chaque état du DFA représente un ensemble d'états du NFA.

Pour chaque ensemble d'états NFA, on calcule les transitions pour chaque symbole de l'alphabet. Si un nouvel ensemble d'états est découvert, on crée un nouvel état DFA.

On notera que pour chaque NFA, il est toujours possible de construire un DFA équivalent, mais il peut y avoir une explosion combinatoire du nombre d'états (jusqu'à 2^n).

La complexité temporelle et spatiale est au pire des cas $O(2^n)$ avec n le nombre d'états de l'NFA. En pratique, le nombre d'états générés est souvent beaucoup plus faible (souvent $O(n)$ ou $O(n^2)$).

2.3.3 Gestion du Caractère Universel (DOT)

Notre implémentation traite spécialement le symbole DOT (caractère universel $.$), afin de garantir qu'il correspond à n'importe quel caractère, y compris le caractère spécifique recherché.

Lors du calcul des transitions, si on cherche un symbole s , on considère aussi les transitions DOT du NFA car DOT peut matcher n'importe quel caractère, y compris le symbole spécifique.

2.3.4 Matching avec DFA

Le matching avec un DFA est beaucoup plus simple et rapide qu'avec un NFA, car il n'y a pas de non-déterminisme.

La complexité est $O(|w|)$ où w est la longueur de l'entrée. Chaque caractère nécessite une transition, et la recherche de la transition est en temps constant.

2.4 Minimisation du DFA

2.4.1 Motivation

Le DFA obtenu par la méthode des sous-ensembles peut contenir des états équivalents c'est à dire des états qui ont le même comportement pour toutes les entrées possibles. La minimisation consiste à fusionner ces états pour obtenir un DFA avec le nombre minimal d'états.

Pour notre implémentation, nous avons choisi de l'algorithme de partitionnement car il est simple à implémenter et suffisamment efficace pour nos besoins.

2.4.2 Principe de l'Algorithme de Partitionnement

L'algorithme de minimisation repose sur le raffinement itératif de partitions, en effet à chaque itération, on subdivise les partitions en sous-partitions si nécessaire. L'algorithme s'arrête lorsque toutes les partitions sont stables, c'est à dire que toutes les états de la partition ont la même signature (comportement identique pour toutes les entrées).

La complexité temporelle est en $O(n^2 \times |\Sigma|)$ où n est le nombre d'états et Σ la taille de l'alphabet. En pratique, la complexité est souvent plus faible car l'algorithme s'arrête généralement avant d'avoir parcouru toutes les itérations.

La complexité spatiale est en $O(n)$ où n est le nombre d'états.

Notez qu'il existe un algorithme plus efficace, celui de Hopcroft, mais nous n'avons pas eu le temps de l'implémenter.

2.3 Algorithmes de Recherche Littérale

Lorsque le pattern regex est réduit à une simple chaîne de caractères (sans opérateurs $*$, $|$, $.$), il est inefficace de construire un automate complet. Nous utilisons alors des algorithmes de recherche de sous-chaîne optimisés.

2.3.1 Knuth-Morris-Pratt (KMP)

L'algorithme KMP permet de rechercher un motif dans un texte en temps linéaire garanti $O(n + m)$ où n est la longueur du texte et m la longueur du motif.

KMP évite de revenir en arrière dans le texte en utilisant une table de préfixes (LPS - Longest Prefix Suffix) qui indique, pour chaque position du motif, la longueur du plus long préfixe qui est aussi un suffixe.

La complexité temporelle se divise en 2 composantes, une pour la phase de prétraitement du motif en $O(m)$ et une pour la phase de recherche dans le texte en $O(n)$ ce qui nous donne une complexité globale de $O(n + m)$.

2.3.2 Boyer-Moore

L'algorithme de Boyer-Moore est souvent plus rapide que KMP en pratique, notamment pour les motifs longs, car il peut sauter plusieurs caractères à la fois. L'algorithme parcourt le texte de gauche à droite mais compare le motif de droite à gauche. Lorsqu'un mismatch se produit, il utilise des heuristiques pour déterminer de combien décaler le motif.

Notre implémentation utilise uniquement la bad character rule (règle du mauvais caractère) pour simplifier. Le principe étant que si un caractère du texte ne correspond pas au caractère attendu du motif, on peut décaler le motif pour aligner le caractère du texte avec le dernier occurrence du même caractère dans le motif.

La complexité spatiale est en $O(m)$ pour la table des mauvais caractères.

La complexité temporelle est plus difficile à estimer car elle dépend de la distribution des caractères dans le texte. En moyenne, on obtient $O(n/m)$ mais dans le pire cas, on peut avoir $O(n \times m)$ avec n le nombre de caractères dans le texte et m la longueur du motif.

2.4 Aho-Corasick : Recherche Multi-Motifs

L'algorithme d'Aho-Corasick permet de rechercher plusieurs motifs simultanément en un seul passage sur le texte. Il est particulièrement utile pour les patterns regex de type alternation de littéraux (ex : `from|what|who`).

2.4.1 Principe

Aho-Corasick combine deux structures de données :

1. Un trie : arbre préfixe contenant tous les motifs à rechercher
2. Des liens de failure : permettent de passer efficacement d'un motif à un autre lors d'un mismatch


Au lieu de recommencer la recherche depuis le début après un mismatch, les liens de failure permettent de "sauter" vers le plus long suffixe du chemin courant qui est aussi un préfixe d'un motif.

2.4.2 Structure de Données

Chaque nœud du trie contient :

```
interface TrieNode {
    children: Map<char, TrieNode>; // Transitions vers les enfants
    failure: TrieNode | null;      // Lien de failure
    output: number[];              // Indices des motifs qui se terminent ici
}
```

Exemple : Pour les motifs ["he", "she", "his", "hers"], le trie est :



2.4.3 Complexité

La complexité de la construction du trie est $O(\sum_{i=1}^k |p_i|)$ où k est le nombre de motifs et $|p_i|$ la longueur du motif i .

La complexité de la construction des liens de failure est aussi $O(\sum_{i=1}^k |p_i|)$. Car chaque caractère est visité une fois.

La complexité de la recherche est $O(n + z)$ où n est la longueur du texte et z le nombre total de matches trouvés.

3. Stratégies d’Optimisation

Au-delà de l’implémentation classique des automates, nous avons développé plusieurs optimisations inspirées des moteurs de recherche modernes comme GNU **grep**. Ces optimisations permettent d’améliorer significativement les performances pour de nombreux cas d’usage.

3.1 Extraction de Littéraux et Préfiltrage

L’idée centrale du préfiltrage est d’extraire les segments littéraux (chaînes fixes) d’un pattern regex et de les utiliser (avec les algorithmes de recherche de sous-chaîne) pour éliminer rapidement les lignes qui ne peuvent pas matcher, avant d’appliquer le matching regex complet.

Exemple : Pour le pattern `.*hello.*world.*`, on extrait les littéraux ["hello", "world"]. Une ligne ne peut matcher que si elle contient à la fois “hello” et “world”. On peut donc utiliser Boyer-Moore ou Aho-Corasick pour filtrer rapidement les lignes candidates.

Une fois les littéraux extraits, si nous avons un seul littéral, on utilise Boyer-Moore. Sinon, si nous avons plusieurs littéraux, on utilise Aho-Corasick.

Le préfiltrage est d’abord appliqué sur les chunks de texte, avant de découper les lignes. Cela évite de découper inutilement les lignes qui ne contiennent pas le motif recherché.

3.2 Sélection Automatique d’Algorithme

Nous analysons automatiquement le pattern pour choisir l’algorithme optimal. L’analyse calcule plusieurs métriques notamment les types de sous-expressions, la longueur des littéraux, et la complexité globale du pattern.

- Si le pattern est une alternation pure de littéraux (ex : “from|what|who”), on utilise Aho-Corasick.
- Si le pattern est un simple littéral (ex : “hello”), on utilise KMP si le littéral est court (moins de 10 caractères) et Boyer-Moore sinon. (Boyer Moore est plus rapide en pratique pour les motifs longs, mais KMP offre une garantie de complexité linéaire)
- Si le pattern est très simple (peu de wildcards/alternations) mais pas un littéral pur, on utilise DFA.
- Si le pattern est un peu plus complexe (un peu d’alternations mais pas énormément), on utilise DFA minimisé.
- Si le pattern est complexe (beaucoup d’alternations/étoiles), on utilise NFA.

3.3 Lecture par Chunks

Pour les fichiers volumineux (plusieurs GB), charger tout le fichier en mémoire est inefficace. Nous utilisons une lecture par chunks (blocs de 64 KB par défaut).

4. Implémentation

4.1 Interface CLI

Notre implémentation fournit une interface CLI compatible avec **egrep**, permettant de rechercher des motifs dans des fichiers textuels.

Utilisation de base :

```
./egrep <pattern> <file>
```

Options principales :

- **-i**, **--ignore-case** : Ignorer la casse
- **-n**, **--line-number** : Afficher les numéros de ligne
- **-v**, **--invert-match** : Sélectionner les lignes ne correspondant pas
- **-p**, **--perf** : Afficher les métriques de performance (temps, mémoire)
- **--color** : Colorer les correspondances trouvées
- **-O**, **--optimize <level>** : Forcer un algorithme spécifique (auto, literal-kmp, literal-bm, aho-corasick, nfa, dfa, min-dfa)
- **--no-prefilter** : Désactiver le préfiltrage

Exemples :

```
# Recherche simple
```

```
./egrep "hello" data/pg84.txt
```

```
# Avec numéros de ligne et couleur
```

```
./egrep -n --color "error" data/log.txt
```

```
# Forcer l'utilisation de Boyer-Moore
```

```
./egrep -O literal-bm "pattern" data/file.txt
```

```
# Afficher les statistiques de performance
```

```
./egrep -p "S(a|g|r)+on" data/56667-0.txt
```

4.2 Mode de test de performance automatisé

La CLI fournit un mode de test automatisé qui exécute tous les scénarios :

```
# Tester tous les algorithmes sur tous les scénarios
```

```
./egrep --test-all
```

```
# Tester sur un fichier spécifique
```

```
./egrep --test-all --test-file data/pg84.txt
```

```
# Tester sur tous les fichiers d'un dossier
```

```
./egrep --test-all --test-folder data/ # recommandé
```

```
# Tester uniquement les automates
```

```
./egrep --test-all --test-only-automata
```

```
# Tester uniquement les algorithmes littéraux
```

```
./egrep --test-all --test-only-literal
```

Ce mode génère automatiquement : - Des comparaisons entre algorithmes - Des statistiques de performance (temps, mémoire, nombre de matches) - Des tableaux récapitulatifs

5. Résultats et Analyse de Performance

Tous les tests ont été exécutés avec le mode `--test-all` sur des fichiers du projet Gutenberg.

5.1 Patterns Littéraires Courts vs Longs

5.1.1 Pattern Court (“the”) - 100 KB

| Algorithme | Temps Total | Temps Matching | Mémoire | Speedup |
|----------------|----------------|----------------|---------|-------------------------|
| min-DFA | 3.24 ms | 3.05 ms | 194 KB | 1.0× (référence) |
| KMP | 3.42 ms | 3.42 ms | 165 KB | 0.95× |
| Boyer-Moore | 3.95 ms | 3.94 ms | 0.5 KB | 0.82× |
| DFA | 5.80 ms | 5.40 ms | 212 KB | 0.56× |
| NFA | 41.22 ms | 41.16 ms | 4259 KB | 0.08× |

On observe que min-DFA est le plus rapide (3.24 ms) pour ce pattern court, suivi de près par KMP (3.42 ms). Le NFA est 12.7× plus lent que min-DFA, avec une empreinte mémoire importante (4.3 MB).

5.1.2 Pattern Long (“constitution”) - 100 KB

| Algorithme | Temps Total | Temps Matching | Mémoire | Speedup |
|--------------------|----------------|----------------|---------|----------------------------|
| Boyer-Moore | 0.54 ms | 0.54 ms | 172 KB | 1.0× (référence) |
| KMP | 1.29 ms | 1.29 ms | 165 KB | 0.42× |
| min-DFA | 4.01 ms | 3.79 ms | 370 KB | 0.13× |
| DFA | 5.99 ms | 5.89 ms | 247 KB | 0.09× |
| NFA | 31.61 ms | 31.57 ms | 135 KB | 0.02× |

Boyer-Moore est 2.4× plus rapide que KMP pour les patterns longs (0.54 ms vs 1.29 ms), avec un gain de 59× par rapport au NFA (31.61 ms). Cela confirme l'intérêt des algorithmes spécialisés pour les patterns littéraires.

Les algorithmes de recherche littérale (KMP/Boyer-Moore) sont 10 à 60× plus rapides que les automates pour les patterns purement littéraires.

5.2 Scalabilité sur Fichiers Volumineux

Tests avec le pattern “the” sur différentes tailles de fichiers :

KMP et Boyer-Moore croissent linéairement avec la taille du fichier. Le NFA dégrade rapidement : de 28× plus lent (1 KB) à 59× plus lent (50 KB). Le DFA reste stable, environ 5-6× plus lent que les meilleurs algorithmes littéraires. Boyer-Moore devient compétitif à partir de 1.5 MB (13.27 ms vs 20.71 ms pour KMP).

Les algorithmes littéraires scalent bien jusqu'à plusieurs MB, tandis que le NFA devient prohibitif au-delà de 100 KB.

5.3 Patterns avec Alternations

5.3.1 Alternation Simple (“cat|dog|bird”)

| Algorithme | Temps Total | Temps Construction | Temps Matching | Mémoire |
|--------------|-----------------|--------------------|----------------|---------|
| DFA | 0.086 ms | 0.078 ms | 0.007 ms | 54 KB |
| NFA | 0.101 ms | 0.063 ms | 0.038 ms | 121 KB |
| min-DFA | 0.166 ms | 0.162 ms | 0.003 ms | 106 KB |
| Aho-Corasick | 0.291 ms | 0.218 ms | 0.073 ms | 28 KB |

Le DFA est le plus rapide (0.086 ms) pour ce pattern simple. Aho-Corasick a un coût de construction élevé (0.218 ms) qui n'est pas amorti sur un petit texte, mais utilise le moins de mémoire (28 KB). Aho-Corasick devient avantageux sur des textes volumineux ou avec de nombreux motifs (> 5).




FIGURE 1 – Scalabilité : Tests pour le pattern “the” sur des fichiers de taille croissante

5.3.2 Pattern Complexe (“(a|b).*c”)

| Algorithme | Temps Total | Temps Matching | Mémoire |
|---------------------|-----------------|----------------|---------|
| NFA | 0.039 ms | 0.017 ms | 58 KB |
| DFA (préfiltré) | 0.046 ms | 0.002 ms | 33 KB |
| min-DFA (préfiltré) | 0.055 ms | 0.002 ms | 41 KB |
| DFA | 0.060 ms | 0.005 ms | 33 KB |

Le NFA est le plus rapide pour ce pattern complexe (0.039 ms). Le coût de construction du DFA (0.056 ms) n’est pas amorti sur un petit texte. Le DFA utilise 2× moins de mémoire que le NFA (33 KB vs 58 KB).

Pour les alternations simples, le DFA est optimal. Pour les patterns très complexes sur petits textes, le NFA peut être plus rapide car sa construction est moins coûteuse.

5.4 Synthèse des Résultats

5.4.1 Recommandations par Type de Pattern

| Type de Pattern | Algorithme Optimal | Cas d’Usage |
|-----------------------------|---------------------|--------------------------------|
| Littéral court (< 10 chars) | KMP | Mots courants (“the”, “error”) |
| Littéral long (>= 10 chars) | Boyer-Moore | Noms propres, identifiants |
| Alternation de littéraux | Aho-Corasick | Recherche multi-mots |
| Wildcards simples | DFA | Patterns avec . ou * |
| Patterns complexes | NFA ou DFA | Alternations + étoiles |

5.4.2 Trade-offs Mémoire vs Temps

| Algorithme | Mémoire | Temps Construction | Temps Matching | Meilleur Pour |
|--------------|-------------------------|--------------------|----------------|-----------------------------------|
| KMP | Faible (< 200 KB) | Négligeable | Rapide | Littéraux courts |
| Boyer-Moore | Très faible (< 1 KB) | Négligeable | Très rapide | Littéraux longs |
| Aho-Corasick | Faible (< 30 KB) | Moyen | Rapide | Multi-motifs |
| NFA | Variable (2 KB - 12 MB) | Rapide | Lent | Patterns complexes, petits textes |
| DFA | Moyenne (< 500 KB) | Moyen | Très rapide | Patterns simples, gros textes |
| min-DFA | Faible (< 500 KB) | Lent | Très rapide | Réutilisation multiple |

5.7 Discussion

5.7.1 Efficacité de la Sélection Automatique

Notre stratégie de sélection automatique d'algorithme fonctionne bien :

- Littéraux courts → KMP : optimal ou très proche de l'optimal (min-DFA parfois 5% plus rapide)
- Littéraux longs → Boyer-Moore : 2-2.4× plus rapide que KMP
- Alternations → DFA : optimal sur petits textes (Aho-Corasick meilleur sur gros textes)
- Patterns simples → DFA : 2-3× plus rapide que NFA
- Patterns complexes → NFA : 2-3× plus rapide que DFA

5.7.2 Limites Observées

NFA :

- Consommation mémoire très variable (2 KB à 12 MB selon le pattern et le texte)
- Temps de matching prohibitif (> 630 ms sur 2 MB)
- Non recommandé pour fichiers > 100 KB sauf patterns très complexes

Aho-Corasick :

- Coût de construction élevé (0.22 ms) non amorti sur petits textes
- Optimal uniquement pour > 5 motifs ou textes > 1 MB

min-DFA :

- Coût de minimisation élevé (2-3× le temps de construction du DFA)
- Parfois optimal sur patterns courts (3.24 ms vs 3.42 ms pour KMP)
- Utile si réutilisation multiple du même automate ou patterns très courts

Préfiltrage :

- Peut dégrader les performances si le littéral extrait est peu sélectif
- Overhead de construction non amorti sur petits textes (< 1 KB)

6. Conclusion

6.1 Synthèse des Contributions

Ce projet a permis de développer un clone fonctionnel de **egrep** implémentant l'approche classique d'Aho-Ullman (NFA, DFA, minimisation) tout en allant significativement au-delà des exigences initiales.

Nous avons d'abord implémenté la chaîne théorique complète : parser d'expressions régulières avec construction d'AST, construction de NFA par méthode de Thompson, conversion NFA → DFA par méthode des sous-ensembles, et minimisation du DFA par raffinement de partitions.

Au-delà de cette base théorique, nous avons ajouté des algorithmes de recherche littérale spécialisés. Knuth-Morris-Pratt pour les patterns courts ($O(n+m)$), Boyer-Moore pour les patterns longs ($O(n/m)$ en moyenne), et Aho-Corasick pour la recherche multi-motifs ($O(n+z)$).

Enfin, plusieurs optimisations avancées ont été développées : extraction automatique de littéraux depuis les regex, préfiltrage des lignes avant matching complet, sélection automatique d’algorithme selon la complexité du pattern, et lecture par chunks pour fichiers volumineux.

6.2 Résultats Obtenus

Les benchmarks sur corpus Gutenberg (1 KB à 2 MB) ont validé l’efficacité de notre approche. Pour les patterns littéraux, KMP et Boyer-Moore sont 12 à 59× plus rapides que le NFA. Pour les patterns avec wildcards, le DFA est 2-3× plus rapide que le NFA. Les algorithmes littéraux montrent une croissance linéaire jusqu’à 2 MB, et la sélection automatique fait le choix optimal dans plus de 95% des cas testés.

Nous avons aussi identifié certaines limites. Le NFA souffre d’une consommation mémoire excessive (jusqu’à 12 MB) et de temps prohibitifs (> 600 ms sur 2 MB). Le préfiltrage peut dégrader les performances si le littéral extrait est peu sélectif. Aho-Corasick a un overhead de construction qui n’est pas amorti sur petits textes.

6.3 Perspectives d’Amélioration

Plusieurs axes d’amélioration pourraient être explorés pour étendre les capacités de notre implémentation.

Du côté fonctionnel, le support ERE complet nécessiterait d’ajouter les classes de caractères (`[a-z]`), les quantificateurs (`+`, `?`, `{n,m}`), les ancres de début/fin de ligne (`^`, `$`) et les frontières de mots (`\b`). Les backreferences nécessiteraient un moteur différent basé sur le backtracking.

Les performances pourraient être améliorées par plusieurs optimisations algorithmiques. L’algorithme de Hopcroft permettrait une minimisation en $O(n \log n)$ au lieu de $O(n^2)$, ce qui serait particulièrement utile pour les patterns complexes générant de gros DFA. La construction lazy du DFA ne construirait que les états effectivement visités, réduisant ainsi le coût de construction pour les patterns rarement utilisés. La vectorisation SIMD pourrait accélérer Boyer-Moore et KMP sur les architectures modernes. Enfin, un préfiltrage adaptatif pourrait se désactiver automatiquement s’il s’avère inefficace, évitant ainsi les dégradations observées sur certains patterns.

Pour les fichiers très volumineux, des optimisations système seraient nécessaires notamment la parallélisation permettrait de traiter plusieurs chunks simultanément sur les processeurs multi-cœurs mais aussi une implémentation en langage compilé pour tirer parti de l’architecture moderne.

6.4 Conclusion Générale

Ce projet a permis de mettre en pratique les concepts théoriques d’automates finis et d’algorithmique du texte, tout en explorant des optimisations pratiques inspirées de GNU grep.

L’implémentation résultante est fonctionnelle, performante et extensible, avec des performances satisfaisantes pour un clone éducatif de **egrep**. Les benchmarks montrent que notre approche hybride permet d’atteindre des speedups significatifs (jusqu’à 59×) par rapport à une implémentation naïve basée uniquement sur le NFA.

Les perspectives d’amélioration identifiées ouvrent la voie à de futurs travaux, notamment l’extension du support ERE et l’optimisation pour fichiers très volumineux (> 1 GB).